

Reguläre Ausdrücke



Dozent: Prof. Dr. Michael Eichberg
Kontakt: michael.eichberg@dhbw.de
Version: 1.3

Folien: [HTML] <https://delors.github.io/lab-regexp/folien.de.rst.html>
[PDF] <https://delors.github.io/lab-regexp/folien.de.rst.html.pdf>
Fehler melden: <https://github.com/Delors/delors.github.io/issues>

Reguläre Ausdrücke

- Reguläre Ausdrücke (📄 *regular expressions*) sind ein Standardwerkzeug zum Patternmatching auf Textdaten.
 - Wir verwenden diese z. B. zum Suchen und Ersetzen in Textdateien,
 - im Rahmen der Entwicklung von Lexern und Parsern,
 - um Eingaben zu überprüfen (Sanitizing) oder
 - um Wörterbücher, Leaks und weitere Kontextinformationen zu Passwortkandidaten zu verarbeiten.
- Reguläre Ausdrücke beschreiben reguläre Sprachen und können durch einen endlichen Automaten erkannt werden.
- Reguläre Ausdrücke nehmen - im Normalfall - immer einen maximalen Musterabgleich vor (📄 *greedy matching / eager matching*).

1. Schreiben von regulären Ausdrücken

Fokus ist hier auf grundlegende reguläre Ausdrücke.

Es gibt verschiedene Dialekte von regulären Ausdrücken. Hier wird der Dialekt verwendet, der von GNU grep mit der Option -E (Extended Regular Expressions) unterstützt wird. Einige Beispiele verwenden Perl-kompatible reguläre Ausdrücke (PCRE), die mit grep -P genutzt werden können.

Reguläre Ausdrücke - Zeichenklassen

Buchstaben und Zahlen können direkt in einem regulären Ausdruck verwenden, um entsprechenden Text zu finden. Zum Beispiel steht "a" für das Zeichen a.

```
1 echo -n "abc" | grep -E "a"
```

findet: a

Der Punkt repräsentiert ein beliebiges Zeichen - außer den Zeilenumbruch.

```
1 echo -n "abc" | grep -E "a."
```

findet: ab

Klassen von Zeichen können in eckigen Klammern angegeben werden "[]".

```
1 echo -n "abcdefg" | grep -E "[acg]"
```

findet: a, c, g

Klassen können auch durch Bereiche beschrieben werden (a-z, A-Z, 0-9):

```
1 echo -n "ab12xy" | grep -Eo "[a-z]"
```

findet: a, b, x, y

Welche Buchstaben genau durch eine Klasse repräsentiert werden hängt von den Spracheinstellungen ab!

```
1 LANG=de_DE.UTF-8; echo "ää" | grep -Eo "[a-z]"
```

findet: a, ä

aber

```
1 LANG=C; echo "ää" | grep -Eo "[a-z]"
```

findet „nur“: a

Die Negation einer Klasse wird durch an ein ^ direkt am Anfang der Klasse erzwungen.

```
1 echo "abc123" | grep -Eo "[^a-z]"
```

findet: 1, 2, 3

Reguläre Ausdrücke - Escapezeichen

Der Backslash \ dient als Escapezeichen für Sonderzeichen.

```
1 echo "abc-123[a-z]" | grep -Eo "[a-z\]"
```

findet: [a-z] (aber nicht "abc")

Reguläre Ausdrücke - Anker

^: Steht für den Anfang einer Zeile.

\$: steht für das Ende einer Zeile.

```
1 $ echo "abcabcabc" | grep -Eo "abc"
2 abc
3 abc
4 abc
5 $ echo "abcY_abcZ" | grep -Eo "^abc."
6 abcY
7 $ echo "XbcYbc" | grep -Eo ".bc$"
8 Ybc
```

Reguläre Ausdrücke - Quantifizierung

*: "null oder mehr" Vorkommen des vorherigen Zeichens oder Musters.

+: "ein oder mehr" Vorkommen des vorherigen Zeichens oder Musters.

?: "null oder ein" Vorkommen des vorherigen Zeichens oder Musters.

```
1 $ echo "Sa--aa--aaaE" | grep -Eo "aa*"
2 a, aa, aaa
3 $ echo "Sa--aa--aaaE" | grep -Eo "aa+"
4 aa, aaa
5 $ echo "Sa--aa--aaaE" | grep -Eo "a?"
6 a, a, a, a, a, a
```

{X, Y}: zwischen X und Y Vorkommen des vorherigen Zeichens oder Musters. Die obere Grenze ist optional, um zum Beispiel X und mehr Vorkommen zu finden.

```
1 $ echo "Sa--aa--aaaE" | grep -Eo "a{2,2}"
2 aa
3 aa
4 $ echo "Sa--aa--aaaE" | grep -Eo "a{2,3}"
5 aa
6 aaa
```

Reguläre Ausdrücke - Alternativen

| trennt verschiedene Alternativen.

```
1 $ echo "HundMausAffe" | grep -Eo "Hund|Affe"
2 Hund
3 Affe
```

Aufgrund des „gierigem“ Musterabgleichs ist bei dem Abgleich von Alternativen im Allgemeinen darauf zu achten, dass zuerst auf längere bzw. spezifischere Muster geprüft wird. Die Regeln sind jedoch

```
1 $ echo "Schiffahrt" | grep -Eo "Schiff|Schiffahrt"
2 Schiffahrt
3
4 # Perl compatible (requires GNU grep)
5 echo "Schiffahrt" | grep -Po "Schiff|Schiffahrt"
6 Schiff
```


Reguläre Ausdrücke - Klammern

() dienen der Gruppierung von Teilausdrücken und der Referenzierbarkeit bzw. Rückreferenzen mittel \$<NR> wobei NR die Nummer der Gruppe ist.

Beispiel: der folgende Ausdruck findet Zeichenketten, die mit dem Zeichen aufhören mit dem sie begonnen haben.

```
1 $ echo "XaaaaX" | grep -Eo "^(.)*\1$"
2 XaaaaX
3
4 $ echo "XaaaaY" | grep -Eo "^(.)*\1$"
```

Reguläre Ausdrücke - Lookahead

(?= . . .) : ist ein positiver Lookahead und stellt sicher, dass ein bestimmtes Muster im Text folgt, ohne es selbst in das Ergebnis aufzunehmen.

(?! . . .) : ist ein negativer Lookahead und stellt sicher, dass ein bestimmtes Muster im Text *nicht* folgt.

```
1 $ echo "HundKatzeHundMaus" | grep -Po 'Hund(?=Katze){1,2}'
2 HundKa
3
4 $ echo "HundKatzeHundMaus" | grep -Po 'Hund(?!Katze){1,2}'
5 HundMa
```

Reguläre Ausdrücke - *Non-capturing Groups*

(?:...): definiert eine Gruppe, die nicht für Rückreferenzen verwendet wird. (Primär für Effizienz.)

```
1 $ echo "abcabc" | grep -Po '(?:abc){2}'  
2 abcabc
```

Reguläre Ausdrücke - *Eager vs. Lazy Matching*

*?: match 0 oder mehr Vorkommen des vorherigen Zeichens oder Musters, aber so wenige wie möglich/nötig

+?: match 1 oder mehr Vorkommen des vorherigen Zeichens oder Musters, aber so wenige wie möglich/nötig

(??: match 0 oder 1 Vorkommen des vorherigen Zeichens oder Musters, aber so wenige wie möglich/nötig

```
1 $ echo '<div>Hallo</div><div>Welt</div>' | grep -Eo '<.*?>'
2 <div>
3 </div>
4 <div>
5 </div>
6 $ echo '<div>Hallo</div><div>Welt</div>' | grep -Eo '<.*>'
7 <div>Hallo</div><div>Welt</div>
```

Fingerübungen

1.1. Schmetterling in Rockyou

Prüfen Sie ob der Begriff: schmetterling oder Schmetterling in der Datei `rockyou.txt` vorkommt.

1.2. Wiederholungen von Zeichen in Passwörtern

Finden Sie alle Passworte in denen ein Zeichen mind. 3 oder mehrmals wiederholt wird. z. B. "x0000!" oder "aaaabbbb".

1.3. Wiederholungen von Sequenzen in Passwörtern

Finden Sie alle Passworte, in denen eine Sequenz mit mindestens 3 Zeichen wiederholt wird, z. B. „TestTest“ oder „1AffeIstAffe#“.

1.4. Kein Sonderzeichen danach

Finden Sie alle Buchstabensequenzen mit ein bis drei Zeichen, bei denen das letzte Zeichen nicht gefolgt wird von einem Sonderzeichen (z. B. `ab` und `de` in „`abc_def_`“).